Cadengo Rodriguez Niels Alexander, Entregable No. 1

Funcionamiento Laboratorio de Ciencia de Datos

El objetivo principal del laboratorio de ciencia de datos es poder ayudar a implementar nuevos métodos y técnicas de ciencia de datos modernas para la producción de información bajo las políticas que rigen los artículos del funcionamiento del laboratorio de ciencia de datos.

El LCiD principalmente se encarga de organizar como es que se van a implementar los nuevos métodos y técnicas de ciencia de datos mencionadas anteriormente, en coordinación con unidades administrativas del plantel y del estado permitiendo la creación e investigación de lagos e datos y areneros de datos favoreciendo al desarrollo de mejores prácticas para aprovechar mejor los datos al ponerlos en producción para obtener nueva información estadística y geográfica. Esto permite el desarrollo de proyectos de investigación referentes al diseño, configuración, uso y explotación de datos para contribuir al fortalecimiento de las capacidades del instituto para poder vigilar y dirigir las implementaciones de políticas del LCiD y poder tomar las estrategias de formación y especialización necesarias para su implementación y poder ser presentada en representación al instituto.

Las subdirecciones se encargan de la toma de decisiones en los procesos de diseño, configuración, uso y explotación de datos utilizando los métodos y técnicas de ciencia de datos para la producción de información estadística y geográfica.
Dentro de sus principales funciones puede concretar que se le asignen las implementaciones de métodos y técnicas, el diseño, configuración, uso y explotación de lagos y areneros de datos, el desarrollo de los proyectos, las acciones de desarrollo, actualizaciones de las políticas de funcionamiento, implementación y seguimiento de políticas, los documentos en materia de ciencia de datos.

Los departamentos tienen el objetivo de analizar el desarrollo, diseño, configuración, uso y explotación de lagos y areneros de datos. Dentro de sus principales funciones tiene que decidir, instrumentar, analizar, vigilar, calcular, suministrar y probar las acciones de desarrollo de proyectos de investigación que sean asignados para el fortalecimiento de las capacidades de la institución donde puede participar en la incubación de proyectos, percepción remota, procesamiento de lenguaje natural, visualización de

información, generación de prototipos de productos y asesoría de implementación de ciencia de datos en proyectos.

Dentro del manual de operaciones se hace mención a INEGI al ser responsable de normar y coordinar el sistema nacional de información estadística y geográfica, así como asignar las actividades que lleven a cabo las unidades del estado con el objetivo de obtener información de interés nacional en base a reglas de operación emitidas para regular las forma en que trabaja el Laboratorio de Ciencia de Datos (LCiD), con la finalidad de mantener los principios establecidos en la ley del sistema nacional de información estadística y geográfica.

Dentro de las disposiciones generales donde se mencionan 8 artículos donde se menciona reglas para establecer las disposiciones de las operaciones dentro del LCiD en el INEGI, así como de prototipos de productos de datos, básicamente estas reglas son observaciones obligatorias para todos los integrantes del LCiD y colaboradores, basándose e los principios de confidencialidad y reserva emitidos por l "Ley Nacional de Información Estadística y Geográfica" y los estándares de conducta establecidos en el código de ética.
Se menciona que el personal asignado en el LCiD debe desempeñar al menos un rol. Dentro de los roles podemos ver que se necesitan;

- Científicos de datos (líder): responsable de supervisar el desarrollo de los proyectos, puede dirigir las investigaciones y decidir los modos y procedimientos para establecer la estrategia dependiendo de las necesidades de infraestructura y desarrollo.
- Científico d datos (sr): responsable de dirigir la implementación de métodos y procedimientos de ciencia de datos y establecer las métricas.
- Científico de datos (jr): responsable de implementar los métodos y procedimientos asi como su documentación.
- Arquitecto de flujo de trabajo: responsable de las especificaciones flujo de trabajo de proyectos.
- Arquitecto de infraestructura: responsable de la configuración y administración de la infraestructura.
- Arquitecto de big data: responsable de determinar la estrategia plataforma tecnológica para la recolección, almacenamiento y procesamiento de grandes volúmenes de datos.

Para la gestión de proyectos se contemplan distintos tipos de participaciones, como;

- Asesoría: brinda asesoría científica y tecnológica en los métodos y técnicas de ciencia de datos, por medio de reuniones de trabajo donde se atienden dudas.
- Acompañamiento: se establece las estrategias y programa de trabajo en conjunto.
- Soporte técnico: facilita el uso de documentación de los componentes involucrados.
- Adopción: provee un prototipo de productos de datos y documento que describe el proceso y procedimientos para el desarrollo.

Estos proyectos se pueden registrar en programas de investigación, se deben generar y presentar documento digital denominado protocolo de investigación el cual tendrá una estructura especifica.

El proyecto se divide en algunas fases;

Fuente de datos: se hace la selección de fuentes de información relevante para el proyecto, estos pueden ser;

- Tradicionales: censos y encuestas.
- Alternativas: geoespaciales, información de terceros públicos y/o privados.
- Metadatos: validaciones semánticas y codificación manual de datos.
- Grandes volúmenes de datos no estructurados.
- Fuentes de datos continuos en tiempo real
- Grupos de datos pequeños que permiten hacer análisis.

Extracción y carga de datos: consiste en la recolección de datos para la implementación de técnicas, se debe considerar;

- métodos automáticos o manuales de extracción de datos.
- Acceso a repositorios externos y/o internos.
- Carga de datos extraídos.

- Aplicación de las trasformaciones.

Recuperación de información: implementar estrategias de búsqueda en los conjuntos de datos que permitan generar grupos de información llamados conjuntos de datos.

Procesamiento de datos: implementación y aplicación de técnicas estadísticas e informáticas para analizar los datos recolectados.

- Análisis exploratorio de datos en base a lo requerimientos.
- Limpieza de datos, control de calidad de información.
- Representación de datos que responda a las necesidades del modelo.

Construcción del modelo: selección de los modelos de aprendizaje y/o estadísticos.
Fase de evaluación y validación e resultados con base a las métricas en cualquier momento durante el desarrollo del proyecto.
En la presentación de resultados se hace la demostración de prototipos de productos de datos, se presenta el reporte técnico que indica la metodología y la construcción de tableros de control durante la producción e un producto.
La entrega de producto de datos consiste en entregar los prototipos al solicitante, este debe estar funcionando en un contenedor y su respectiva documentación, se puede incluir asesoría.

Contenerización

La contenerización de aplicaciones consiste en aislar aplicaciones del sistema operativo, empaquetándolas con todos los componentes y dependencias necesarios para que se puedan ejecutar en cualquier entorno. Con el uso de contenedores, las aplicaciones se vuelven portables, pudiendo utilizarse en diferentes entornos, ya que incorporan todo lo necesario para su ejecución.
Para que una aplicación pueda ejecutarse necesita librerías, archivos de configuración, puerto de red, dependencias y archivos binarios, entre otros componentes. Un contenedor aísla todos esos elementos junto a la aplicación, consiguiendo separarla del sistema operativo, facilitando que pueda ser ejecutada en distintas clases de infraestructuras.

Portabilidad

Un contenedor podrá ejecutarse en entornos locales, híbridos o en la nube sin necesidad de realizar cambios de código.

Seguridad

La contenerización de aplicaciones incrementa su nivel de seguridad al ofrecer mayor aislamiento de los paquetes de aplicaciones. Al ejecutar solo las dependencias y procesos necesarios para su ejecución, los contenedores ofrecen un entorno menos vulnerable que un sistema operativo virtualizado.

Escalabilidad

Al ser elementos pequeños e independientes son fácilmente escalables, ayudando a crear infraestructuras realmente complejas con miles de contenedores, de manera rápida y sencilla (utilizando un orquestador de contenedores como Kubernetes).

Rentabilizar los recursos

Con la contenerización de aplicaciones se evita el uso de recursos innecesarios del servidor, algo que no se puede evitar al utilizar máquinas virtuales, donde se recrea un sistema operativo completo haciendo uso de muchos recursos de hardware.

Podman

Podman (administrador de pods) es una herramienta open source para desarrollar, gestionar y ejecutar los contenedores en los sistemas Linux. se desarrolló Podman para gestionar el ecosistema completo de contenedores. Funciona en las principales distribuciones de Linux,como Ubuntu, Fedora, CentOS, Debian y RHEL.

Además de renunciar a un daemon central, otra de las características más destacadas de Podman son los denominados pods. Estos pods, inspirados en el concepto de los pods de Kubernetes, son la fusión de varios contenedores en un namespace común de Linux que comparten recursos concretos. De esta manera, se pueden combinar una amplia variedad de aplicaciones virtualizadas.

Evidencia máquina virtual RHEL y podman

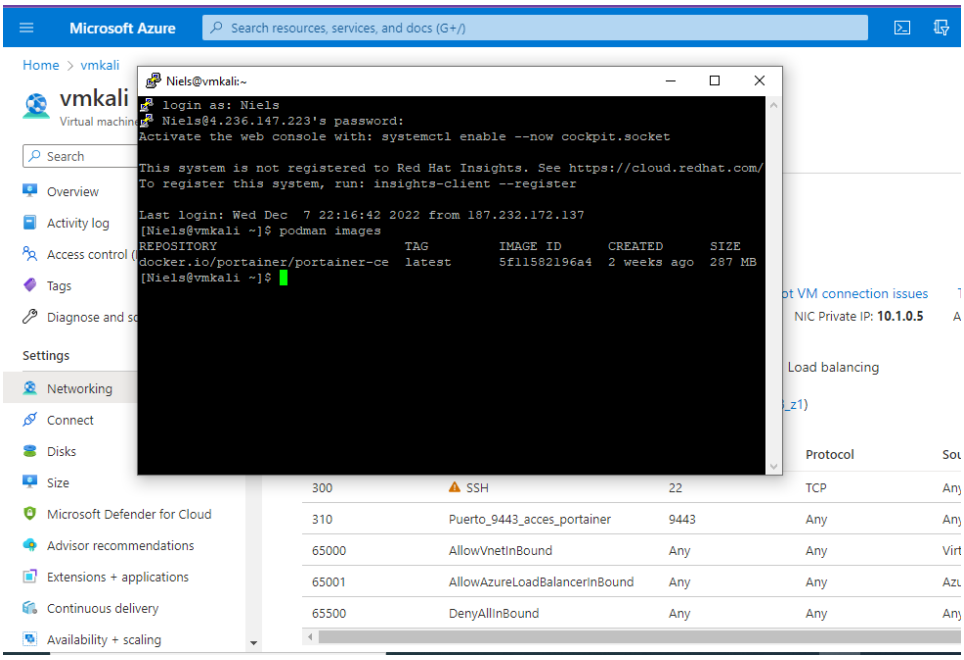

lcid@inegi.org.mx