Cadengo Rodriguez Niels Alexander, Entregable No. 6

Creación manual de linaje de datos apache atlas con formato JSON.

El linaje de datos explica cómo fluyen los datos en el sistema, como dónde se originan, qué transformaciones se le aplicaron, a dónde se movió, etc.

Para crear el líneage de datos necesitamos hacerlo en el lenguaje nativo que utiliza atlas, en este caso puede ser JSON o XML.

En apache atlas se deberá hacer referencia a una entidad, que será el nodo que representara cualquier tipo de datos, en atlas cada entidad deberá ser con respecto a su tipo de datos y estas pueden tener entradas y salidas, se pueden representar nodos que hagan referencia a un proceso donde va a dar otro dato como salida.

Definimos las entidades en la estructura de atlas y en formato JSON.

salesGermany.json

```
{
  "entity": {
    "typeName": "DataSet",
    "attributes": {
      "owner": "inegi",
      "qualifiedName": "DataSet_Germany_sales",
      "description": "sales_from_Germany.txt",
      "name": "sales_from_Germany.txt"
    }
  }
}
```

salesCanada.json


```
{
  "entity": {
    "typeName": "DataSet",
    "attributes": {
      "owner": "inegi",
      "qualifiedName": "DataSet_Canada_sales",
      "description": "sales_from_Canada.txt",
      "name": "sales_from_Canada.txt"
    }
  }
}
```


profitGermany.json


```
{
  "entity": {
    "typeName": "DataSet",
    "attributes": {
      "owner": "inegi",
      "qualifiedName": "profit_in_Germany ",
      "description": "profit in Germany ",
      "name": "profit_in_Germany.txt"
    }
  }
}
```

profitCanada.json


```
{
  "entity": {
    "typeName": "DataSet",
    "attributes": {
      "owner": "inegi",
      "qualifiedName": "DataSet_profit_Canada",
      "description": "profit in Canada",
      "name": "profit_in_Canada.txt"
    }
  }
}
```


ventasglobales Germany Canada.json


```
{
  "entity": {
    "typeName": "DataSet",
    "attributes": {
      "owner": "Krishna Maj",
      "qualifiedName": "global sales Germany Canada",
      "description": "global sales Germany Canada",
      "name": "global_sales_ Germany Canada.txt"
    }
  }
}
```

Con la ayuda del comando curl y haciendo referencia a la API de Apache Atlas cargaremos el contenido de estos archivos de forma manual.

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/entity -d @salesFrom Germany.json

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/entity -d @salesFromCanada.json

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/entity -d @profitInCanada.json

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/entity -d @profitIn Germany.json

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/entity -d @globalSales Germany Canada.json

Al crear cada uno este nos genera un ID que tendremos que guardar para poder hacer las relaciones entre las entidades ya creadas.

salesFrom Germany.json generated the id: "19e1b839-bf0e-450d-8bdd-2e44b00ea87c"

salesFromCanada.json generated the id: "3508b7bf-ad31-48ed-9013-030d9c3d10e8"

profitInCanada.json generated the id: "7012df53-a1e6-464d-a407-39e04714cf8d"

profitIn Germany.json generated the id: "f1646aa0-5144-4e74-9907-6c1e6b96fdbf"

globalSales Germany Canada.json generated the id: "95324b7d-e6f9-4fa7-a2a4-83c194beba54"

Definimos las entidades tipo proceso que serán las que van a tener las relaciones.

mergerProcess.json


```
{
  "entityDefs": [
    {
      "category": "ENTITY",
      "name": "merger_process",
      "description": "Merge the data",
      "attributeDefs": [
        {
          "name": "startTime",
          "typeName": "long",
          "isOptional": true,
          "cardinality": "SINGLE",
          "valuesMinCount": 0,
          "valuesMaxCount": 1,
          "isUnique": false,
          "isIndexable": false,
          "includeInNotification": false,
          "searchWeight": -1
        },
        {
          "name": "endTime",
          "typeName": "long",
          "isOptional": true,
          "cardinality": "SINGLE",
          "valuesMinCount": 0,
          "valuesMaxCount": 1,
          "isUnique": false,
          "isIndexable": false,
```

```
        "includeInNotification": false,
        "searchWeight": -1
      }
    ],
    "superTypes": [
      "Process"
    ]
  }
 ]
}
```


mapAndReduceProcess.json


```
{
 "entityDefs": [
  {
    "category": "ENTITY",
    "name": "map_reduce_process",
    "description": "Map and Reduce process",
    "attributeDefs": [
      {
        "name": "startTime",
        "typeName": "long",
        "isOptional": true,
        "cardinality": "SINGLE",
        "valuesMinCount": 0,
        "valuesMaxCount": 1,
        "isUnique": false,
        "isIndexable": false,
        "includeInNotification": false,
        "searchWeight": -1
      },
      {
        "name": "endTime",
```

```
        "typeName": "long",
        "isOptional": true,
        "cardinality": "SINGLE",
        "valuesMinCount": 0,
        "valuesMaxCount": 1,
        "isUnique": false,
        "isIndexable": false,
        "includeInNotification": false,
        "searchWeight": -1
      }
    ],
    "superTypes": [
      "Process"
    ]
  }
 ]
}
```


De igual manera cargamos las entidades con el comando curl y haciendo referencia a al API.

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/types/typedefs -d @mapAndReduceProcess.json

curl -X POST -u admin:admin -H 'accept: application/json' -H 'cache-control: no-cache' -H 'content-type: application/json' http://localhost:21000/api/atlas/v2/types/typedefs -d @mergerProcess.json

Crear primer linaje

Vamos a crear una instancia de fusion_process con entradas salesFrom Germany.json y salesFromCanada.json y salida globalSales Germany Canada.json.

fusionProcessInstance.json

{
"entidad" : {
"typeName" : "merger_process" ,
"atributos" : {
"propietario" : "inegi" ,
"salidas" : [
{ "guid" : "95324b7d-e6f9-4fa7-a2a4-83c194beba54" ,
"typeName" : "DataSet"
}
], "qualifiedName" : "mergeSalesDaily@file_merge" ,
"displayName" : "Fusionar ventas" ,
"entradas" : [
{ "guid" :

"19e1b839-bf0e-450d-8bdd-2e44b00ea87c" ,
"typeName" : "DataSet"
},
{ "guid" : "3508b7bf-ad31-48ed-9013-030d9c3d10e8" ,
"typeName" : "DataSet"
}
], "descripción " : "Combinar datos de ventas diarios con el archivo de ventas globales" ,
"name" : "mergeSalesDailyFrom Germany Canada" ,
"startTime" : 1643363556 ,
"endTime" :1643364556 ,

```
      "Id. de proceso" :

     "salesMergeProcess Germany Canada"
    }
  }
}
```

Ejecutamos el comando curl para definir la entidad.

curl -X POST -u admin:admin -H 'aceptar: aplicación/json' -H 'control de caché: sin caché' -H 'tipo de contenido: aplicación/json' http://localhost:21000/api/ atlas/v2/entidad -d @mergerProcessInstance.json

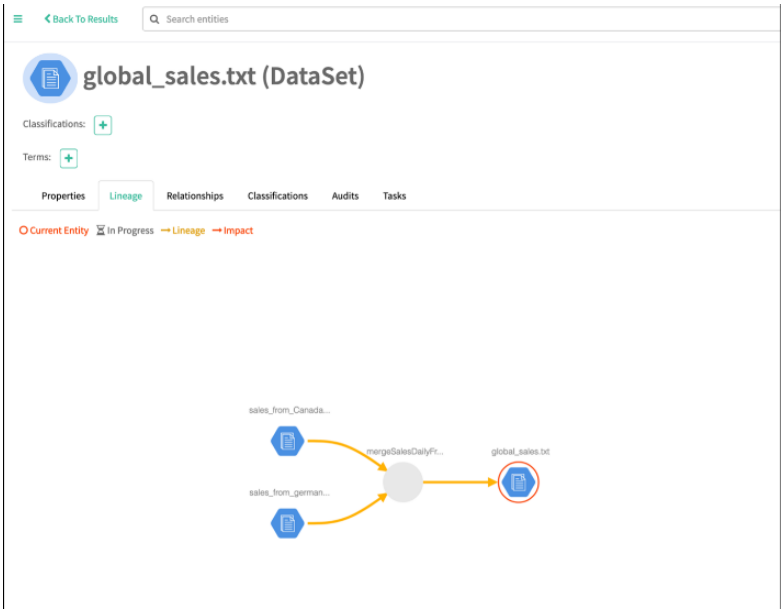

Crear segundo linaje.

mapReduceProcessInstance.json

{
"entidad" : {
"typeName" : "map_reduce_process" ,
"atributos" : {
"propietario" : "inegi" ,
"salidas" : [
{ "guid" : "7012df53-a1e6-464d-a407-39e04714cf8d" ,
"typeName" : "DataSet"
},
{ "guid" : "f1646aa0-5144-4e74-9907-6c1e6b96fdbf" ,
"typeName" : "DataSet"
}
], "nombre calificado" :

"mapReduceProcess@mapReduce Germany Canada" ,
"displayName" : "Mapa Reducir ventas Germany Canada" ,
"inputs" : [
{ "guid" : "95324b7d-e6f9-4fa7-a2a4-83c194beba54" ,
"typeName" : "DataSet"
}
], "description" : "mapa reduce las ventas diarias en Germany, Canada" ,
"name" : "mapa reduce las ventas diarias en Germany, Canada" ,
"startTime" : 1643363556 ,
"hora de finalización" : 1643364556 ,

"processId" : "mapReduceProcess"
}
}

}

Ejecutamos comando curl para crear el lineage.

curl -X POST -u admin:admin -H 'aceptar: aplicación/json' -H 'control de caché: sin caché' -H 'tipo de contenido: aplicación/json' http://localhost:21000/api/ atlas/v2/entidad -d @mapReduceProcessInstance.json